Universidad de Buenos Aires

Facultad de Ciencias Exactas y Naturales
Cálculo Estocástico

Difusiones y Score

La matemática detrás de los modelos generativos modernos

Autor: Gonzalo Josué Spina

Julio de 2026

Índice general

1. Introducción 2

2. Procesos de Difusión 2

3. Evolución de la densidad de un proceso 4

4. Reverse Time Diffusion 6

5. Score y Song 8

Referencias 11

1. Introducción

Los modelos de difusión se volvieron muy populares en el último tiempo, al punto tal que estamos comenzando a ver cortos y videos en redes sociales y plataformas de streaming que se asemejan a producciones hollywoodenses con presupuestos millonarios. Esta monografía pretende presentar, en forma ordenada y resumida, los principales resultados que sustentan y dan lugar a las ecuaciones que explican el principio de funcionamiento de estos modelos.

Podemos pensar en los datos (ya sean imágenes, audio o incluso texto que encontramos en diferentes fuentes o generamos a través de una cámara) como realizaciones de una distribución subyacente desconocida, de la cual, si logramos obtener una buena estimación, podemos generar un sinfín de muestras distintas.

El método consiste en partir de un dataset o conjunto de realizaciones, siendo estas representativas de la distribución subyacente y cuya función de distribución poblacional desconocemos; agregar ruido progresivamente en el tiempo mediante una ecuación diferencial estocástica; obtener una nueva distribución en un tiempo final T; y luego realizar el camino inverso para obtener una estimación de la distribución original. Este proceso de agregado de ruido, como veremos, no es ad hoc, y la posterior estimación de la distribución original depende de poder estimar con precisión la evolución de su función de densidad a lo largo del tiempo para construir la dinámica inversa.

2. Procesos de Difusión

Dentro del marco teórico de las ecuaciones diferenciales estocásticas, definimos una difusión como un proceso estocástico $X_t = X(t, \omega)$ que satisface una ecuación diferencial estocástica de Itô (EDE) de la forma

$$\mathrm{d}X_t = u(t, X_t)\ \mathrm{d}t + \sigma(t, X_t)\ \mathrm{d}B_t, \tag{2.1}$$

con condición inicial $X_0 = Z$, donde

$$u : [0, T] \times \mathbb{R}^d \longrightarrow \mathbb{R}^d$$

es una función que determina la evolución determinista del proceso,

$$\sigma : [0, T] \times \mathbb{R}^d \longrightarrow \mathbb{R}^{d\times m}$$

determina la intensidad y la dirección del ruido, y B_t es un movimiento browniano m-dimensional respecto de una filtración $(\mathcal{F}_t)_{t\geq 0}$. La solución X_t debe ser, a su vez, un proceso adaptado a esta filtración.

Equivalentemente, (2.1) se interpreta en su forma integral como

$$X_t = Z + \int_0^t u(s, X_s)\ \mathrm{d}s + \int_0^t \sigma(s, X_s)\ \mathrm{d}B_s. \tag{2.2}$$

El coeficiente $u(t, x)$ se conoce como *drift* o coeficiente de deriva, mientras que $\sigma(t, x)$ se denomina coeficiente de difusión. El primero describe la evolución local determinista del proceso, mientras que el segundo determina cómo actúa el ruido browniano sobre este.

El siguiente teorema muestra que, si imponemos ciertas condiciones sobre ambos coeficientes, la ecuación posee una única solución. Aunque esta solución no siempre puede calcularse de forma explícita, es posible aproximarla mediante métodos numéricos.

Teorema 2.1 (Existencia y unicidad)**.** *Sean u y σ funciones medibles para las cuales existen constantes $C, D > 0$ tales que, para todo $t \in [0,T]$ y $x, y \in \mathbb{R}^d$,*

$$\|u(t,x) - u(t,y)\| + \|\sigma(t,x) - \sigma(t,y)\| \leq C\,\|x - y\|\,, \tag{2.3}$$

y

$$\|u(t,x)\|^2 + \|\sigma(t,x)\|^2 \leq D\Big(1 + \|x\|^2\Big). \tag{2.4}$$

Si Z es $\mathcal{F}_0$-medible y satisface $\mathbb{E}[\|Z\|^2] < \infty$, entonces la EDE

$$\mathrm{d}X_t = u(t, X_t)\ \mathrm{d}t + \sigma(t, X_t)\ \mathrm{d}B_t, \qquad X_0 = Z,$$

admite una única solución fuerte y continua X_t en el intervalo $[0,T]$.

La condición (2.3) es una condición de Lipschitz global y garantiza la unicidad de la solución, mientras que la condición (2.4), denominada condición de crecimiento lineal, evita que la solución explote en tiempo finito.

Notación 2.2. Escribimos $\mathbb{E}^x[\,\cdot\,] := \mathbb{E}[\,\cdot \mid X_0 = x]$ para denotar la esperanza condicionada al evento $\{X_0 = x\}$.

Ejemplo 2.1 (Proceso de Ornstein–Uhlenbeck)**.** El *proceso de Ornstein–Uhlenbeck* (OU) es la difusión en $\mathbb{R}$ definida por

$$\mathrm{d}X_t = -X_t\ \mathrm{d}t + \sigma\ \mathrm{d}B_t, \qquad X_0 = x_0, \tag{2.5}$$

con $\sigma > 0$. Los coeficientes $u(t,x) = -x$ y $\sigma(t,x) = \sigma$ son globalmente Lipschitz y de crecimiento lineal, de modo que el Teorema 2.1 garantiza existencia y unicidad de la solución.

La solución explícita se obtiene por variación de la constante:

$$X_t = x_0\, e^{-t} + \sigma \int_0^t e^{-(t-s)}\ \mathrm{d}B_s.$$

Por las propiedades de la integral de Itô, $X_t \mid X_0 = x_0$ es gaussiana con

$$\mathbb{E}^{x_0}[X_t] = x_0\, e^{-t}, \qquad \mathrm{Var}(X_t \mid X_0 = x_0) = \frac{\sigma^2}{2}\Big(1 - e^{-2t}\Big).$$

Cuando $t \to \infty$, la media tiende a 0 y la varianza tiende a $\sigma^2/2$, independientemente del valor inicial x_0: la distribución de X_t converge a $\mathcal{N}(0,\, \sigma^2/2)$.

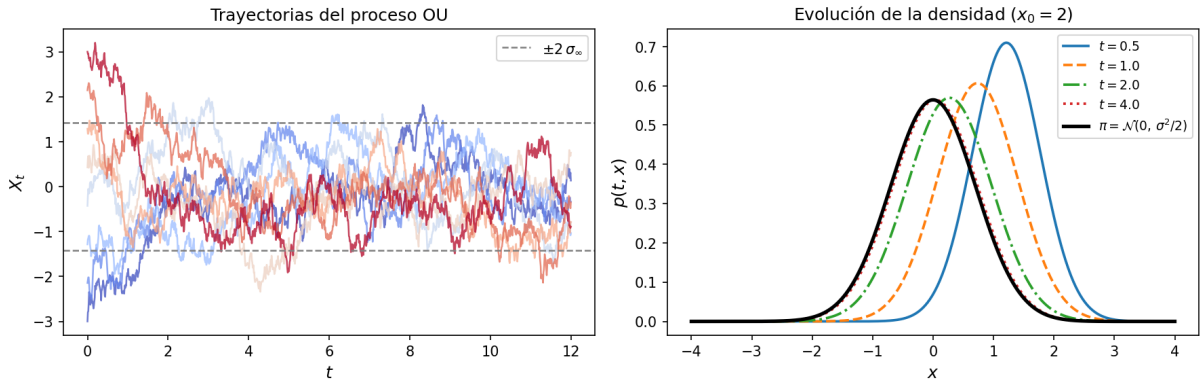


Figura 2.1: Izquierda: trayectorias del proceso OU con $\sigma = 1$ partiendo de distintas condiciones iniciales $x_0 \in [-3, 3]$. Las líneas punteadas indican la banda $\pm 2\sigma_\infty$ de la distribución estacionaria. Derecha: densidad $p(t,\cdot)$ partiendo de $x_0 = 2$ en distintos instantes; la curva negra es $\pi = \mathcal{N}(0, \sigma^2/2)$.

3. Evolución de la densidad de un proceso

El objetivo de este capítulo es entender cómo evoluciona en el tiempo la distribución de un proceso de difusión. Dado que la densidad $p_t(x) = p(t,x)$ del proceso X_t contiene toda la información de su distribución en el instante t, conocerla nos permite entender y reconstruir dicha distribución por completo. Más precisamente, si X_t admite una densidad $p(t,x)$, queremos caracterizar la ecuación en derivadas parciales que esta densidad satisface. Para llegar a ese resultado necesitamos introducir antes el generador infinitesimal del proceso, que describe la tasa de cambio de la esperanza de cualquier observable, y las ecuaciones de Kolmogorov, que conectan esa perspectiva con la evolución de $p(t,x)$.

Como las difusiones son procesos de Markov, la evolución infinitesimal condicionada al estado actual $X_t = x$ no depende de toda la historia del proceso. Esto permite definir el siguiente operador, que cuantifica la tasa de cambio de la esperanza de cualquier observable $f : \mathbb{R}^d \to \mathbb{R}$.

Definición 3.1 (Generador infinitesimal)**.** Sea $(X_t)_{t\geq 0}$ una difusión de Markov. Su *generador infinitesimal* es el operador diferencial lineal definido por

$$\mathcal{A}_t f(x) = \lim_{h\downarrow 0} \frac{\mathbb{E}[f(X_{t+h}) \mid X_t = x] - f(x)}{h},$$

para toda función $f \in \mathcal{D}_{\mathcal{A}}(x)$, donde $\mathcal{D}_{\mathcal{A}}(x)$ es el conjunto de funciones para las cuales este límite existe en x.

El generador puede interpretarse como el análogo de la derivada en el cálculo diferencial: describe la tasa instantánea de variación de la esperanza del observable $f(X_t)$.

Los siguientes resultados nos permiten calcular el generador de un proceso.

Lema 3.2. *Sea X_t un proceso en $\mathbb{R}^d$ de la forma*

$$X_t(\omega) = x + \int_0^t u(s,\omega)\ \mathrm{d}s + \int_0^t v(s,\omega)\ \mathrm{d}B_s(\omega),$$

con $X_0 = x$. Sea $f \in C^2(\mathbb{R}^d)$ con soporte compacto. Supongamos que $u(t,\omega)$ y $v(t,\omega)$ son acotadas en (t,ω) de forma tal que $X_t(\omega)$ permanece en el soporte de f. Entonces

$$\mathbb{E}^x[f(X_t)] = f(x) + \mathbb{E}^x\left[\int_0^t \left(\sum_{i=1}^d u_i(s,\omega)\,\frac{\partial f}{\partial x_i}(X_s) + \frac{1}{2}\sum_{i,j=1}^d (vv^\top)_{i,j}(s,\omega)\,\frac{\partial^2 f}{\partial x_i\,\partial x_j}(X_s)\right)\mathrm{d}s\right].$$

Teorema 3.3. *Sea X_t una difusión que satisface la ecuación (2.1) y sea $f \in C_0^2(\mathbb{R}^d)$. Entonces $f \in \mathcal{D}(\mathcal{A})$ y*

$$\mathcal{A}_t f(x) = \sum_{i=1}^d u_i(t,x)\,\frac{\partial f}{\partial x_i}(x) + \frac{1}{2}\sum_{i,j=1}^d (\sigma\sigma^\top)_{i,j}(t,x)\,\frac{\partial^2 f}{\partial x_i\,\partial x_j}(x). \tag{3.1}$$

Combinando el Lema 3.2 y el Teorema 3.3, obtenemos el equivalente al teorema central del cálculo.

Teorema 3.4 (Fórmula de Dynkin)**.** *Sea $f \in C^2(\mathbb{R}^d)$. Entonces*

$$\mathbb{E}^x[f(X_t)] = f(x) + \mathbb{E}^x\left[\int_0^t \mathcal{A}_s f(X_s)\ \mathrm{d}s\right]. \tag{3.2}$$

La fórmula de Dynkin, además de ser un resultado central en sí mismo, es el ingrediente clave para obtener las dos ecuaciones de Kolmogorov. La primera, que presentamos a continuación, describe cómo evoluciona la esperanza de un observable condicionada al estado actual; la segunda, que derivaremos enseguida, gobierna la evolución de la densidad.

Teorema 3.5 (Ecuación de Kolmogorov hacia atrás)**.** *Sea X_t una difusión que satisface (2.1), sea $T > 0$ y sea $f \in C_b^2(\mathbb{R}^d)$. Supongamos además que los coeficientes u^i y $a^{ij} = (\sigma\sigma^\top)^{ij}$ son Hölder continuos en (t,x) y que a es uniformemente elíptica, es decir, existe $\lambda > 0$ tal que*

$$\sum_{i,j=1}^{d} a^{ij}(t,x)\,\xi_i\xi_j \geq \lambda|\xi|^2 \qquad \forall\,(t,x) \in [0,T]\times\mathbb{R}^d,\ \forall\,\xi\in\mathbb{R}^d.$$

Entonces la función $v(t,x) = \mathbb{E}\Big[f(X_T) \mid X_t = x\Big]$ pertenece a $C^{1,2}([0,T)\times\mathbb{R}^d)$ y es la única solución clásica de

$$\frac{\partial v}{\partial t}(t,x) + \mathcal{A}_t v(t,x) = 0, \qquad (t,x)\in[0,T)\times\mathbb{R}^d,$$

con condición terminal $v(T,x) = f(x)$.

Para encontrar la ecuación que gobierna la densidad $p(t,x)$, partimos de la fórmula de Dynkin. Supongamos que X_t admite una densidad $p(t,\cdot)$ para cada $t \geq 0$. Reescribiendo la esperanza como integral contra p:

$$\int_{\mathbb{R}^d} f(x)\,p(t,x)\,\mathrm{d}x = \int_{\mathbb{R}^d} f(x)\,p(0,x)\,\mathrm{d}x + \int_0^t \int_{\mathbb{R}^d} \mathcal{A}_s f(x)\,p(s,x)\,\mathrm{d}x\,\mathrm{d}s.$$

Diferenciando respecto de t (el intercambio con la integral se justifica por convergencia dominada bajo la hipótesis $p \in C^{1,2}(\mathbb{R}^d)$):

$$\frac{\mathrm{d}}{\mathrm{d}t}\int_{\mathbb{R}^d} f(x)\,p(t,x)\,\mathrm{d}x = \int_{\mathbb{R}^d} f(x)\,\frac{\partial p}{\partial t}(t,x)\,\mathrm{d}x = \int_{\mathbb{R}^d} \mathcal{A}_t f(x)\,p(t,x)\,\mathrm{d}x.$$

Queremos trasladar el operador $\mathcal{A}_t$ de f a p. Para ello definimos su adjunto en $L^2(\mathbb{R}^d)$.

Definición 3.6 (Operador adjunto del generador)**.** El *operador adjunto* $\mathcal{A}_t^*$ es el operador que satisface

$$\int_{\mathbb{R}^d} (\mathcal{A}_t f)(x)\,p(x)\,\mathrm{d}x = \int_{\mathbb{R}^d} f(x)\,(\mathcal{A}_t^* p)(x)\,\mathrm{d}x$$

para toda $f \in C_0^2(\mathbb{R}^d)$ y toda densidad p suficientemente regular.

Con esta definición la ecuación anterior se reescribe como

$$\int_{\mathbb{R}^d} f(x)\,\frac{\partial p}{\partial t}(t,x)\,\mathrm{d}x = \int_{\mathbb{R}^d} f(x)\,\Big(\mathcal{A}_t^*\,p(t,\cdot)\Big)(x)\,\mathrm{d}x,$$

y como esto vale para toda $f \in C_0^2(\mathbb{R}^d)$, concluimos que p satisface la siguiente ecuación.

Teorema 3.7 (Fokker-Planck)**.** *Bajo las mismas hipótesis de regularidad y elipticidad del Teorema 3.5, sea $p_0 \in C(\mathbb{R}^d)\cap L^1(\mathbb{R}^d)$ una densidad de probabilidad. Entonces existe una única densidad $p \in C^{1,2}((0,T]\times\mathbb{R}^d)$ que satisface*

$$\frac{\partial p}{\partial t} = \mathcal{A}_t^*\,p,$$

con condición inicial $p(0,x) = p_0(x)$. Calculando explícitamente $\mathcal{A}_t^*$ mediante integración por partes a partir del Teorema 3.3:

$$\frac{\partial p}{\partial t} = -\sum_{i=1}^{d} \frac{\partial}{\partial x_i}\Big[u_i(t,x)\,p(t,x)\Big] + \frac{1}{2}\sum_{i,j=1}^{d} \frac{\partial^2}{\partial x_i\,\partial x_j}\Big[(\sigma\sigma^\top)_{i,j}(t,x)\,p(t,x)\Big]. \tag{3.3}$$

Ejemplo 3.1 (Fokker-Planck del proceso OU)**.** Para el proceso OU (2.5) con $u(t,x) = -x$ y $a(t,x) = \sigma^2$, la ecuación de Fokker-Planck toma la forma

$$\frac{\partial p}{\partial t} = \frac{\partial}{\partial x}(x\,p) + \frac{\sigma^2}{2}\frac{\partial^2 p}{\partial x^2}.$$

Se verifica directamente que la densidad de $\mathcal{N}(0,\, \sigma^2/2)$ satisface $\mathcal{A}^* p_\infty = 0$: es la distribución estacionaria del proceso, en acuerdo con la solución explícita del Ejemplo 2.1.

4. Reverse Time Diffusion

Hasta aquí hemos estudiado cómo un proceso de difusión que parte de una distribución inicial X_0 evoluciona hacia adelante en el tiempo. En este capítulo nos interesa el camino inverso: dado un proceso en el instante $T > 0$, construir un proceso que corra hacia atrás y recupere la distribución original de X_0. Veremos que este proceso inverso es también una difusión.

Para formalizar la idea, definimos el proceso con el tiempo invertido como

$$\hat{X}_t = X_{T-t}, \qquad t \in [0, T],$$

y buscamos coeficientes $\hat{u}$, $\hat{\sigma}$ y un movimiento browniano $\hat{B}_t$ tales que $\hat{X}_t$ satisfaga una EDE. Puede demostrarse que el proceso invertido conserva la propiedad de Markov (usando la inversión temporal de la propiedad de Markov de X_t). El contenido no trivial del resultado es que $\hat{X}_t$ satisface una EDE, lo que requiere construir explícitamente un proceso auxiliar $\tilde{B}_t$ y demostrar que posee la propiedad de movimiento browniano respecto de la filtración *decreciente* $\mathcal{F}_t^{\downarrow} = \sigma(X_s, \tilde{B}_s : s \geq t)$. Esto es lo que demuestra Anderson [And82] en su Sección 4.

Teorema 4.1 (Inversión temporal, Anderson)**.** *Bajo las hipótesis técnicas de regularidad, densidad, integrabilidad y unicidad del resultado de inversión temporal de Anderson [And82], denotamos* $a(t,x) = \sigma(t,x)\sigma(t,x)^\top$ *y definimos*

$$\hat{u}^{\,i}(t,x) = -u^i(T-t,x) + \frac{1}{p(T-t,x)}\frac{\partial}{\partial x_j}\Big[a^{ij}(T-t,x)\,p(T-t,x)\Big],$$
$$\hat{\sigma}(t,x) = \sigma(T-t,x),$$

con la convención de que $\hat{u}^{\,i}(t,x) = 0$ *cuando* $p(T-t,x) = 0$*. Entonces existe un movimiento browniano* r*-dimensional* $\hat{B}_t$ *tal que* $(\hat{X}_t)_{0\leq t\leq T}$ *es una difusión de Markov que satisface*

$$\mathrm{d}\hat{X}_t = \hat{u}(t, \hat{X}_t)\ \mathrm{d}t + \hat{\sigma}(t, \hat{X}_t)\ \mathrm{d}\hat{B}_t,$$

con generador

$$\hat{\mathcal{A}}_t f(x) = \frac{1}{2}\sum_{i,j=1}^{d} a^{ij}(T-t,x)\,\frac{\partial^2 f}{\partial x_i\,\partial x_j}(x) + \sum_{i=1}^{d}\hat{u}^{\,i}(t,x)\,\frac{\partial f}{\partial x_i}(x).$$

Esquema formal. El desarrollo siguiente identifica los coeficientes inversos, pero no constituye una prueba autosuficiente de la afirmación de inversión temporal a nivel de trayectorias; la construcción del browniano inverso y sus hipótesis técnicas son las de Anderson [And82].

Paso 1: identificación del generador. Sea $f \in C_0^2(\mathbb{R}^d)$ y denotemos $p_t = p(t,\cdot)$. Por definición del generador:

$$\hat{\mathcal{A}}_t f(x) = \lim_{h\downarrow 0} \frac{\mathbb{E}[f(X_{T-t-h}) \mid X_{T-t} = x] - f(x)}{h}.$$

Escribimos $p_{X_r|X_s=y}(x)$ para la densidad de transición del proceso forward: la densidad de X_r dado $X_s = y$, evaluada en x, con $s < r$. Denotamos $g(h) = \mathbb{E}[f(X_{T-t-h}) \mid X_{T-t} = x]$. Aplicando la fórmula de Bayes para densidades condicionales para pasar de la transición forward $p_{X_{T-t}|X_{T-t-h}=y}(x)$ a la condicional backward $p_{X_{T-t-h}|X_{T-t}=x}(y)$:

$$g(h) = \int_{\mathbb{R}^d} f(y)\, \frac{p_{X_{T-t}|X_{T-t-h}=y}(x)\; p_{T-t-h}(y)}{p_{T-t}(x)}\; \mathrm{d}y.$$

Para $h > 0$, la densidad de transición $p_{X_{T-t}|X_{T-t-h}=y}(x)$ es suave en y por regularidad elíptica. Aplicando la regla del producto al integrando:

Término (I). La ecuación de Kolmogorov backward establece, para $h > 0$:

$$\frac{d}{dh}\, p_{X_{T-t}|X_{T-t-h}=y}(x) = \mathcal{A}^y_{T-t-h}\, p_{X_{T-t}|X_{T-t-h}=y}(x).$$

Término (II). Por la ecuación de Fokker-Planck:

$$\frac{d}{dh}\, p_{T-t-h}(y) = -(\mathcal{A}^*_{T-t-h}\, p_{T-t-h})(y).$$

Como $p_{X_{T-t}|X_{T-t-h}=y}(x)$ es suave para $h > 0$, la dualidad en L^2 se aplica sin restricciones al Término (I). Combinando ambos términos:

$$p_{T-t}(x)\, \frac{d}{dh}\, g(h) = \int_{\mathbb{R}^d} p_{X_{T-t}|X_{T-t-h}=y}(x) \Big[(\mathcal{A}^*_{T-t-h}(f\cdot p_{T-t-h}))(y) - f(y)\, (\mathcal{A}^*_{T-t-h}\, p_{T-t-h})(y)\Big]\; \mathrm{d}y.$$

Reescribiendo el factor $p_{X_{T-t}|X_{T-t-h}=y}(x)\, p_{T-t-h}(y) = p_{T-t}(x)\, p_{X_{T-t-h}|X_{T-t}=x}(y)$ mediante Bayes y expandiendo con la regla de Leibniz sobre $\mathcal{A}^*$:

$$\frac{d}{dh}\, g(h) = \int_{\mathbb{R}^d} p_{X_{T-t-h}|X_{T-t}=x}(y) \left[\frac{1}{2}\sum_{i,j} a^{ij}_{T-t-h}(y)\, \partial^2_{y_i y_j} f + \sum_i c^i_h(y)\, \partial_{y_i} f\right] \mathrm{d}y,$$

donde $c^i_h(y) = -u^i_{T-t-h}(y) + \frac{\partial_{y_j}(a^{ij}_{T-t-h}(y)\, p_{T-t-h}(y))}{p_{T-t-h}(y)}$. Tomando $h \to 0^+$: la distribución condicional $p_{X_{T-t-h}|X_{T-t}=x}$ converge débilmente a la masa puntual en x, de modo que la integral evalúa el integrando en $y = x$ y $h = 0$:

$$\hat{\mathcal{A}}_t f(x) = \frac{1}{2}\sum_{i,j} a^{ij}(T-t,x)\, \frac{\partial^2 f}{\partial x_i \partial x_j} + \sum_i \hat{u}^{\,i}(t,x)\, \frac{\partial f}{\partial x_i},$$

con $\hat{u}^i(t,x) = -u^i(T-t,x) + \frac{\partial_{x_j}(a^{ij}(T-t,x)\, p_{T-t}(x))}{p_{T-t}(x)}$, que coincide exactamente con los coeficientes del enunciado.

Paso 2: construcción de $\hat{B}_t$ (Anderson [And82], Secc. 4).

Trabajamos en tiempo forward $t \in [t_0, T]$. Definimos el proceso auxiliar $\tilde{B}_t$ (r-dimensional) por $\tilde{B}_{t_0} = 0$ y

$$\mathrm{d}\tilde{B}^k_t = \mathrm{d}B^k_t + \frac{1}{p(t,X_t)} \sum_{j=1}^{d} \frac{\partial}{\partial x^j}\Big[p(t,X_t)\, \sigma^{jk}(t,X_t)\Big]\; \mathrm{d}t, \quad k = 1,\dots,r.$$

El proceso conjunto $(X_t, \tilde{B}_t)$ satisface el sistema:

$$\mathrm{d}X_t^i = u^i(t, X_t)\ \mathrm{d}t + \sum_k \sigma^{ik}(t, X_t)\ \mathrm{d}B_t^k, \tag{A}$$

$$\mathrm{d}\tilde{B}_t^k = \mathrm{d}B_t^k + \frac{1}{p(t, X_t)} \sum_j \frac{\partial (p\,\sigma^{jk})}{\partial x^j}(t, X_t)\ \mathrm{d}t. \tag{B}$$

Lema 1. *Sea* $\phi(\beta, t) = [2\pi(t - t_0)]^{-r/2} \exp\!\big(-\|\beta\|^2/[2(t - t_0)]\big)$. *La densidad conjunta de* $(X_t, \tilde{B}_t)$ *factoriza como* $p(x, \beta, t) = p(x, t)\,\phi(\beta, t)$.

Demostración. La ecuación de Fokker-Planck para la densidad conjunta de (A)–(B) tiene términos de deriva y difusión en x, en $\tilde{B}$ y cruzados $(x, \tilde{B})$. Sustituimos el ansatz $p(x,t)\phi(\beta,t)$: los términos en x dan $\phi\,\partial_t p$; los de difusión en $\tilde{B}$ dan $p\,\partial_t \phi$ por la ecuación del calor. Los términos de deriva en $\tilde{B}$ y de difusión cruzada tienen la forma $\pm(\partial_{\beta^k}\phi)\cdot\sum_j \partial_{x^j}(p\sigma^{jk})$ y se cancelan entre sí. Queda $\partial_t(p\phi)$, que coincide con el lado izquierdo. La condición inicial $p(x, \beta, t_0) = p(x, t_0)\delta(\beta)$ se verifica, y la unicidad da la factorización. □

Lema 2. X_t *y* $\tilde{B}_t - \tilde{B}_s$ *son independientes para todo* $t \geq s \geq t_0$.

Demostración. Del Lema 1, $p(\tilde{B}_t \mid X_t = x, t) = \phi(\tilde{B}_t, t)$ no depende de x, luego X_t y $\tilde{B}_t$ son independientes. Repitiendo el argumento condicionando en $\tilde{B}_s$ se obtiene que $\tilde{B}_t - \tilde{B}_s \sim \mathcal{N}(0, (t-s)I)$ independientemente de X_t (Anderson, Lemas 3–5). □

$\tilde{B}_t$ como browniano hacia atrás. Definimos la filtración *decreciente* $\mathcal{F}_t^{\downarrow} := \sigma(X_s, \tilde{B}_s : s \geq t)$. Del Lema 2, $\tilde{B}_t - \tilde{B}_{t+s}$ es independiente de $\mathcal{F}_{t+s}^{\downarrow}$ y tiene distribución $\mathcal{N}(0, sI)$, lo que da las condiciones de movimiento browniano respecto de $\mathcal{F}_t^{\downarrow}$:

$$\mathbb{E}\Big[\tilde{B}_t \mid \mathcal{F}_{t+s}^{\downarrow}\Big] = \tilde{B}_{t+s},$$
$$\mathbb{E}\Big[(\tilde{B}_t - \tilde{B}_{t+s})(\tilde{B}_t - \tilde{B}_{t+s})^{\top} \mid \mathcal{F}_{t+s}^{\downarrow}\Big] = s\,I.$$

EDE del proceso inverso. Despejando $\mathrm{d}B_t^k$ de (B) y sustituyendo en (A):

$$\mathrm{d}X_t^i = \Big[u^i - \tfrac{1}{p}\sum_j \partial_{x^j}(p\,a^{ij})\Big]\,\mathrm{d}t + \sum_k \sigma^{ik}\ \mathrm{d}\tilde{B}_t^k,$$

usando $\sum_k \sigma^{ik}\sigma^{jk} = a^{ij}$ y la corrección de Stratonovich para integrales hacia atrás (Anderson [And82], p. 321). Reparametrizando con $\tau = T - t$, $\hat{X}_\tau = X_{T-\tau}$ y

$$\hat{B}_\tau = \tilde{B}_T - \tilde{B}_{T-\tau},$$

que es un movimiento browniano estándar respecto de la filtración natural de $\hat{X}$, se obtiene la EDE del enunciado:

$$\mathrm{d}\hat{X}_\tau = \hat{u}(\tau, \hat{X}_\tau)\ \mathrm{d}\tau + \sigma(T - \tau, \hat{X}_\tau)\ \mathrm{d}\hat{B}_\tau.$$ □

5. Score y Song

En su paper de 2021, Song et al. [Son+21] introducen un framework unificado para la generación de datos que descansa enteramente en la maquinaria que desarrollamos en los

capítulos anteriores. La idea central es la siguiente: dado un conjunto de realizaciones de una distribución desconocida p_0, se construye una EDE hacia adelante que transforma progresivamente p_0 en una distribución conocida p_T (típicamente una gaussiana) elegida como prior. Gracias al Teorema 4.1, existe un proceso de difusión que recorre el camino inverso: parte de p_T y recupera p_0. El coeficiente de deriva del proceso inverso depende del gradiente del logaritmo de la densidad p_t, que se conoce como el *score* del proceso. Si se logra aprender el score para todo $t \in [0, T]$, es posible simular el proceso inverso y generar nuevas muestras de p_0.

Ergodicidad y convergencia al prior. El proceso forward transforma p_0 en p_T, pero para poder samplear el punto de partida del proceso inverso necesitamos conocer p_T. Si el proceso forward es *ergódico*, es decir, olvida la condición inicial y converge a una única distribución estacionaria π, entonces para T suficientemente grande $p_T \approx \pi$ independientemente de p_0, y podemos samplear desde π directamente. El proceso OU satisface esta condición (véase el Ejemplo 3.1) con $\pi = \mathcal{N}(0, \sigma^2/2)$.

El score y su rol en la difusión inversa.

Definición 5.1 (Score)**.** Dado un proceso de difusión X_t con densidad $p(t, x)$, se define el *score* como

$$s(t, x) = \nabla_x \log p(t, x).$$

Para ver cómo aparece naturalmente en la dinámica inversa, retomamos el Teorema 4.1. Cuando $\sigma = \sigma(t)$ depende solo del tiempo, la matriz $a^{ij}(t, x) = \sigma(t)^2 \delta^{ij}$ es diagonal y sus derivadas espaciales se anulan. El drift inverso se simplifica a

$$\hat{u}(t, x) = -u(T - t, x) + \sigma(T - t)^2 \nabla_x \log p(T - t, x),$$

y la EDE del proceso inverso queda

$$\mathrm{d}\hat{X}_t = \left[-u(T - t, \hat{X}_t) + \sigma(T - t)^2 \nabla_x \log p(T - t, \hat{X}_t)\right] \mathrm{d}t + \sigma(T - t)\ \mathrm{d}\hat{B}_t. \tag{5.1}$$

El score es el único ingrediente de esta ecuación que no está disponible directamente: u y σ son coeficientes del proceso forward, elegidos por el modelador, pero $\nabla_x \log p(t, x)$ depende de la distribución desconocida p_0 a través de la evolución de la densidad.

Ejemplo 5.1 (Score y difusión inversa en el proceso OU)**.** Para el proceso OU (2.5) con $u(t, x) = -x$ y σ constante, el drift inverso (5.1) queda

$$\mathrm{d}\hat{X}_t = \left[\hat{X}_t + \sigma^2 \nabla_x \log p(T - t, \hat{X}_t)\right] \mathrm{d}t + \sigma\ \mathrm{d}\hat{B}_t,$$

partiendo de $\hat{X}_0 \sim \mathcal{N}(0, \sigma^2/2)$. El drift cambia de signo respecto del proceso forward ($-x \to +x$): mientras el forward empuja el proceso hacia 0, el reverse lo aleja, y el score corrige esa dinámica para recuperar la forma de p_0.

Escribimos $p_{X_t|X_0=x_0}(x)$ para la densidad de transición del proceso: la densidad de X_t dado $X_0 = x_0$, evaluada en x. Por la ley de probabilidad total, la densidad marginal satisface

$$p(t, x) = \int p_{X_t|X_0=x_0}(x)\, p_0(x_0)\ \mathrm{d}x_0,$$

que para el OU queda $p(t, x) = \int \mathcal{N}(x;\, x_0 e^{-t},\, \frac{\sigma^2}{2}(1 - e^{-2t}))\, p_0(x_0)\ \mathrm{d}x_0$. Esta integral depende de la desconocida p_0, por lo que el score marginal $\nabla_x \log p(T - t, x)$ no es

computable directamente. En cambio, como $p_{X_t|X_0=x_0}(x)$ es gaussiana, el score condicional evaluado en x es analítico:

$$\nabla_x \log p_{X_t|X_0=x_0}(x) = -\frac{x - x_0\, e^{-t}}{\frac{\sigma^2}{2}(1 - e^{-2t})}.$$

La red $s_\theta(t, x_t)$ se entrena para predecir este score condicional sobre pares (x_0, x_t) generados por el proceso forward, y luego se sustituye como aproximación del score marginal en la EDE inversa.

Aprendizaje del score: denoising score matching. El puente formal entre el score marginal y el score condicional es la siguiente identidad [Hyv05]. Diferenciando $p(t,x) = \int p_{X_t|X_0=x_0}(x)\, p_0(x_0)\, \mathrm{d}x_0$ bajo la integral y aplicando Bayes para reescribir $p_{X_t|X_0=x_0}(x)\, p_0(x_0)/p(t,x) = p_{X_0|X_t=x}(x_0)$:

$$\nabla_x \log p(t,x) = \int \nabla_x \log p_{X_t|X_0=x_0}(x) \cdot p_{X_0|X_t=x}(x_0)\ \mathrm{d}x_0.$$

Fijado $X_t = x$, se promedia el score condicional (función de x_0) contra el posterior de la condición inicial dado que el proceso vale x al tiempo t. Vincent [Vin11] y Song & Ermon [Son+21] observaron que el minimizador de $\mathbb{E}[\|s_\theta - \nabla_x \log p_t\|^2]$ coincide con el del objetivo computable

$$\tilde{J}(\theta) = \int_0^T \lambda(t)\, \mathbb{E}_{p_0(x_0)\, p(x_t|x_0)} \left[\left\| s_\theta(t, x_t) - \nabla_{x_t} \log p_{X_t|X_0=x_0}(x_t) \right\|^2 \right] \mathrm{d}t,$$

donde la esperanza se toma sobre pares (x_0, x_t) con $x_0 \sim p_0$ y $x_t \mid x_0$ simulado por el proceso forward.

Algoritmo de generación. Con s_θ entrenado se sustituye en la EDE inversa (5.1) y se integra por Euler–Maruyama [Øks03] con paso $\Delta t = T/N$:

1. Samplear $x_T \sim \pi = \mathcal{N}(0, \sigma^2/2)$.
2. Para $k = N, N-1, \ldots, 1$ con $t_k = k\Delta t$: samplear $z_k \sim \mathcal{N}(0, I)$ y actualizar

$$x_{t_{k-1}} = x_{t_k} + \left[-u(t_k, x_{t_k}) + \sigma(t_k)^2\, s_\theta(t_k, x_{t_k}) \right] \Delta t + \sigma(t_k) \sqrt{\Delta t}\ z_k.$$

3. Retornar $x_0 \sim p_0$ (aproximado).

Experimento numérico. Para ilustrar el método, tomamos como p_0 una distribución Gamma desplazada para tener media 0, construimos el proceso OU forward con $\sigma = 1$ y $T = 5$, y aprendemos el score con una red neuronal entrenada por denoising score matching. La Figura 5.1 muestra que las muestras generadas reproducen fielmente la distribución original (test de Kolmogorov–Smirnov: $p = 0{,}69$).

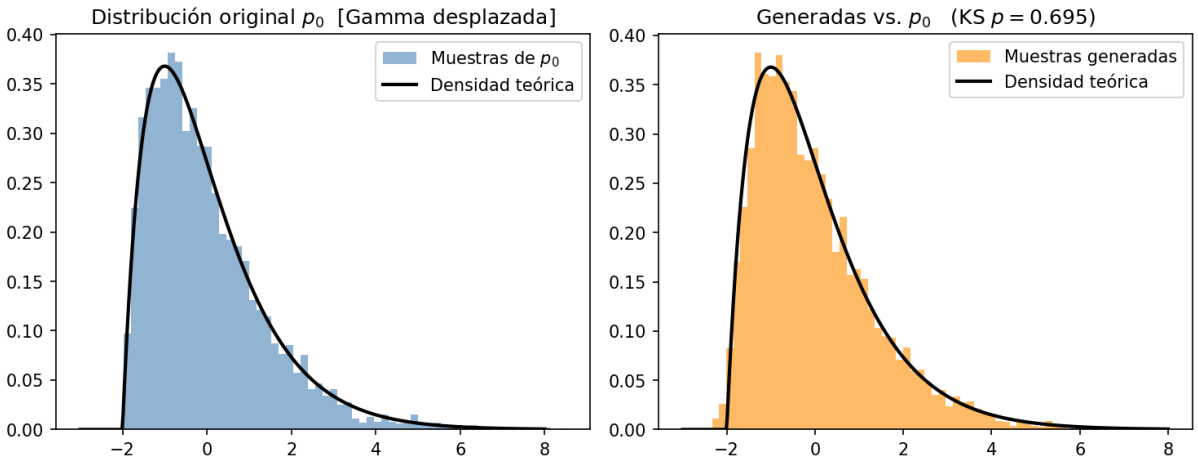


Figura 5.1: Izquierda: muestras reales de p_0 (Gamma desplazada) y su densidad teórica. Derecha: muestras generadas por el proceso inverso superpuestas a la misma densidad.

Referencias

[And82] Brian D. O. Anderson. "Reverse-time diffusion equation models". En: *Stochastic Processes and their Applications* 12.3 (1982), págs. 313-326.

[Hyv05] Aapo Hyvärinen. "Estimation of Non-Normalized Statistical Models by Score Matching". En: *Journal of Machine Learning Research* 6 (2005), págs. 695-709.

[Øks03] Bernt Øksendal. *Stochastic Differential Equations: An Introduction with Applications*. 6.ª ed. Berlin: Springer, 2003.

[Son+21] Yang Song y col. "Score-Based Generative Modeling through Stochastic Differential Equations". En: *International Conference on Learning Representations*. 2021.

[Vin11] Pascal Vincent. "A Connection Between Score Matching and Denoising Autoencoders". En: *Neural Computation* 23.7 (2011), págs. 1661-1674.